

Análisis de Sensibilidad

Ramón Molinero-Parejo

2023-02-13

1. Introducción

La metodología propuesta se basa en una simplificación de los métodos de **Análisis de Sensibilidad Global** (GSA, por sus siglas en inglés *Global Sensitivity Analysis*) (Saltelli et al., 2000). No se introducen variaciones probabilísticas en los factores de entrada. En su lugar, se realiza una eliminación progresiva de los factores originales, con un diseño factorial completo, calculando el resultado del modelo para todas las combinaciones posibles de los factores de entrada.

La comparación de los resultados espaciales obtenidos a partir de las distintas simulaciones permite determinar en qué difieren, evaluar su solidez, y analizar con facilidad las posibles implicaciones espaciales resultantes para la zona estudiada.

Para evaluar los resultados del método, es necesario comparar entre sí los resultados de las simulaciones obtenidas. Esta evaluación se realiza comparando los mapas simulados obtenidos con el mapa simulado considerado de referencia, es decir, el mapa simulado con todos los factores simultáneamente. La **Precisión Total** (OA, *Overall Accuracy*) es la métrica de comparación utilizada para observar el acuerdo de todas las parcelas en su conjunto. También se recomienda utilizar la **Precisión del Productor** (PA, *Producer Accuracy*) para observar el acuerdo para cada clase por separado. Esta métrica nos indica la frecuencia con la que las características reales del mapa de referencia se muestran correctamente en el mapa simulado con n factores. Se calcula dividiendo el área coincidente de ambos mapas para una única clase, entre el área total del mapa de referencia de esa misma clase. Dado que este es un breve tutorial para aprender a aplicar la metodología de GSA, únicamente se van a utilizar OA. Es posible replicar la metodología para los valores PA de cada clase sustituyendo los valores de acuerdo.

2. Modelo de simulación

El modelo de simulación vectorial basado en autómatas celulares (LP-CA, por sus siglas en inglés **Land Parcel Cellular Automata**) calcula el potencial de transición P de una parcela i hacia un nuevo uso del suelo k en un tiempo determinado t . A través del producto de varios factores, se determina el uso del suelo que posee mayor potencial de transición, el cual será asignado a la parcela analizada. La fórmula es la siguiente:

$$P_{i,k}^t = v \cdot A_i \cdot S_{i,k} \cdot N_{i,k,d}^t$$

donde:

- $P_{i,k}^t$ indica el potencial de transición de una parcela i , con un uso del suelo k en un tiempo t
- V representa la aleatoriedad o factor estocástico (X_1)
- A_i representa la accesibilidad (X_2)
- $S_{i,k}$ representa la aptitud (X_3)

- $N_{i,k,d}^t$ representa la Vecindad de una parcela i , con un uso del suelo k , dentro de una distancia d , en un tiempo t (X_5)

3. Análisis de sensibilidad global

Partimos de que el resultado del **modelo LP-CA** es una función de los factores implementados. En nuestro caso tenemos cuatro factores. Sea un modelo Y , el resultado de:

$$Y = f(X) = f(X_1, X_2, X_3, X_4)$$

La varianza de los resultados del modelo Y puede explicarse como la suma de las varianzas de cada uno de los cinco factores (X_1, X_2, X_3, X_4), más la suma de las varianzas de los factores dos a dos ($X_{1,2}, X_{1,3}, X_{1,4}, X_{2,3}, X_{2,4}, X_{3,4}$), más la suma de las varianzas de los factores tres a tres ($X_{1,2,3}, X_{1,2,4}, X_{1,3,4}, X_{2,3,4}$), más la suma de los factores cuatro a cuatro ($X_{1,2,3,4}$). Esta varianza la denominamos **Varianza Total** denotada normalmente como $V(Y)$.

$$V(Y) = \sum_i V_i + \sum_{i < j} V_{i,j} + \sum_{i < j < m} V_{i,j,m} + \dots + V_{1,2, \dots k}$$

donde:

$$V_i = V[E(Y|X_i = x_i^*)]$$

$$V_{ij} = V[E(Y|X_i = x_i^*, Y|X_j = x_j^*)] - V[E(Y|X_i = x_i^*)] - V[E(Y|X_j = x_j^*)]$$

y así sucesivamente. $E(Y|X_i = x_i^*)$ indica la expectativa de Y condicional a que X_i tenga un valor fijo x_i^* , y el operador $V[\bullet]$ indica la varianza condicional.

Si dividimos cada varianza parcial V_1, V_2, V_3, V_4 y V_5 entre $V(Y)$ obtenemos los **Efectos Principales** o **Índices de Varianza de Primer Orden**. La interpretación de estos es sencilla. Por ejemplo VX_1 nos indica la proporción de varianza es explicada por el factor de aleatoriedad por sí mismo. El índice de sensibilidad de primer orden S_i para el factor X_i se define como:

$$S_i = V_i / V(Y)$$

Con el resto de índices ocurre lo mismo. Si dividimos $V_{1,2}$ entre $V(Y)$ nos da la proporción de varianza explicada por la interacción del factor de aleatoriedad (X_1) con el factor de accesibilidad (X_2) (y viceversa). Para los Índices totales, basta con sumar estas varianzas. Por ejemplo, en el caso del factor de aleatoriedad (X_1), deberemos sumar las varianzas que incluyan este factor en su combinación (subíndice 1) de $V_1, V_{1,2}, V_{1,3}, V_{1,4}, V_{1,2,3}, V_{1,2,4}, V_{1,3,4}, V_{1,2,3,4}$ teniendo así el efecto total del factor de aleatoriedad (X_1).

4. Aplicación de la metodología

Para analizar en qué medida influye cada uno de los factores, se deben generar todas las combinaciones posibles de factores en el modelo LP-CA. Para ello, vamos a generar una matriz donde se muestren todas las combinaciones posibles, donde 1 indica presencia del factor X_n y 0 indica ausencia del factor X_n durante la ejecución del modelo.

```
# matriz binaria
n <- 4 #número máximo de factores utilizados
df <- expand.grid(rep(list(0:1), n)) #creación de la matriz con las combinaciones
colnames(df) <- c('X1', 'X2', 'X3', 'X4') #nombre de los factores (columnas)
```

La matriz de combinaciones obtenida es de gran utilidad para ejecutar los 15 modelos (16 - 1 ya que la combinación 1 no se ha de generar al no implicar ningún factor en ella) de las posibles combinaciones de factores. Para este ejemplo únicamente se van a utilizar los valores de OA. Tras ejecutar los 15 modelos,

recopilaremos los resultados de comparar la simulación obtenida del modelo de referencia (aquel que implica todos los factores: $vASN$) con cada una de las simulaciones obtenidas del cada modelo restante. En este sentido, el modelo Y1, que no utiliza ningún factor, reportará un valor de OA de 0.00 %, mientras que el modelo Y16 reportará un valor de OA de 100.00 %, ya que Y16 también es el modelo de referencia, y se compara con sí mismo.

Vamos a utilizar los siguientes valores de OA como ejemplo y los vamos a unir a nuestra tabla con las 16 combinaciones posibles:

```
# valores de precisión total (OA)
OA <- c(0.00, 64.55, 6.58, 52.49, 82.78, 78.29, 76.17, 73.76,
        95.79, 94.36, 95.40, 94.88, 97.95, 98.02, 96.08, 100.00)

# unión por columnas
df['OA'] <- OA
```

Los resultados deberían mostrar una tabla como la que se muestra a continuación (**Tabla 1**). Ahora, ya tenemos los datos necesarios para realizar el **GSA**. Recuerda que estos valores deben ser sustituidos por los obtenidos de comparar la simulación de referencia ($vASN$) con cada combinación simulada (p.ej: v , AN , vAN , etc.).

Table 1: Combinaciones de factores para el modelo LP-CA.

Modelo	X_1	X_2	X_3	X_4	Precisión total
$Nulo$	0	0	0	0	0.00
X_1	1	0	0	0	64.55
X_2	0	1	0	0	6.58
X_{12}	1	1	0	0	52.49
X_3	0	0	1	0	82.78
X_{13}	1	0	1	0	78.29
X_{23}	0	1	1	0	76.17
X_{123}	1	1	1	0	73.76
X_4	0	0	0	1	95.79
X_{14}	1	0	0	1	94.36
X_{24}	0	1	0	1	95.40
X_{124}	1	1	0	1	94.88
X_{34}	0	0	1	1	97.95
X_{134}	1	0	1	1	98.02
X_{234}	0	1	1	1	96.08
X_{1234}	1	1	1	1	100.00

En primer lugar calculamos la media (\bar{x}) para posteriormente obtener la varianza $V(Y)$ del conjunto de modelos (16). La función $var()$ de R calcula la variancia utilizando la siguiente fórmula:

$$s^2 = \sum (x - \bar{x})^2 / n - 1$$

Esta fórmula se aplica generalmente para muestras de datos. Sin embargo, dado que no estamos utilizando una muestra, sino el conjunto de datos total, es decir, lo que se denomina población, podemos generar una nueva función que sustituya $n - 1$ por n . Además, para el cálculo de la varianza parcial en los próximos cálculos necesarios para la obtención de los efectos principales, se utilizará la media total de todos los modelos y no la media del conjunto analizado.

$$\sigma^2 = \sum (x - \bar{x})^2 / n$$

La función es la siguiente:

```
# nueva varianza
new.var <- function(x){
  x = as.numeric(x)
  x = na.omit(x)
  m = m.y
  return(sum((x - m)**2, na.rm = TRUE) / length(x))
}
```

Ahora podemos calcular la precisión total media de los 16 modelos con la función `mean()`, así como la varianza, utilizando la nueva función `new.var()` que hemos creado.

```
# estadísticas
m.y <- mean(df$OA)      #media
v.y <- new.var(df$OA)    #varianza
```

Sobre el marco de datos vamos a crear una nueva columna que denominaremos *n.OA*, donde vamos a almacenar los efectos principales calculados para cada modelo. Desde los efectos de primer orden, hasta los de cuarto orden.

```
# creación de nueva columna
df['n.OA'] = 0
```

Los efectos de primer orden son los más sencillos de calcular. En primer lugar, debemos calcular la varianza parcial de cada factor individualmente. Posteriormente, dividimos la varianza parcial entre la varianza total, obteniendo así el **Efecto principal** o **Índice de varianza de primer orden** del factor X_1 . Los pasos a seguir son:

1. Cálculo de la media de los modelos que cumplan: $X_1 = 1$. Recordemos que $X_1 = 1$ significa presencia de ese factor en el modelo y $X_1 = 0$ ausencia.

$$E_1 = (X_1 + X_{12} + X_{13} + X_{14} + X_{123} + X_{124} + X_{134} + X_{1234}) / 8$$

2. Cálculo de la media de los modelos que cumplan: $X_1 = 0$.

$$E_2 = (X + X_2 + X_3 + X_4 + X_{23} + X_{24} + X_{34} + X_{234}) / 8$$

3. Cálculo de la varianza parcial de ambos valores obtenidos.

$$PV_1 = (E_1 - \bar{x})^2 + (E_2 - \bar{x})^2 / 2$$

donde \bar{x} representa la media global para todos los modelos.

4. Resta de las varianzas de los modelos de orden anterior (que compartan factor) a la varianza parcial obtenida para este modelo. En este caso, al no haber ordenes inferiores, no hay restar ningún valor.

$$V_1 = PV_1$$

5. División de la varianza del modelo X_1 entre la varianza total.

$$S_1 = V_1 / V(Y)$$

donde $V(Y)$ representa la varianza global para todos los modelos.

El resultado obtenido (S_1) se correspondería con el **Efecto principal** o **Índice de varianza de primer orden** del modelo X_1 , en este caso, del factor de Aleatoriedad (v).

NOTA: Las funciones creadas de primer, segundo y tercer orden calculan la media de OA para todos los modelos que cumplen la condición establecida (Ej.: modelos con presencia del factor X_1). Así, va calculando las medias para todas las condiciones y las agrega a una lista con la función *append()*. Por último, aplica la función *new.var()* al conjunto de valores existentes en esa lista. En el caso del cálculo de los Efectos de primer orden, esta función se corresponde con los pasos 1, 2 y 3. En ciertas líneas de código está asignado el paso al que hace referencia (#n).

```
## Primer orden ####
v.x <- function(x1){
  m.x <- c()
  m.x <- append(m.x, mean(df[df[x1] == 1,][[5]])) #1
  m.x <- append(m.x, mean(df[df[x1] == 0,][[5]])) #2
  var.x <- new.var(m.x) #3
  return(var.x)
}

v1 <- v.x('X1'); df[2,6] <- v1 / v.y #5
v2 <- v.x('X2'); df[3,6] <- v2 / v.y #5
v3 <- v.x('X3'); df[5,6] <- v3 / v.y #5
v4 <- v.x('X4'); df[9,6] <- v4 / v.y #5
```

En cuanto a los **Índices de varianza de segundo orden**, el cálculo requiere más elaboración, ya que se deben tener en cuenta todas las combinaciones posibles (presencia / ausencia) de los dos factores implicados. Los pasos a seguir para del factor X_{12} son:

1. Cálculo de la media de los modelos que cumplan: $X_1 = 1 \mid X_2 = 1$.

$$E_1 = (X_{12} + X_{123} + X_{124} + X_{1234}) / 4$$

2. Cálculo de la media de los modelos que cumplan: $X_1 = 1 \mid X_2 = 0$.

$$E_2 = (X_1 + X_{13} + X_{14} + X_{134}) / 4$$

3. Cálculo de la media de los modelos que cumplan: $X_1 = 0 \mid X_2 = 1$.

$$E_3 = (X_2 + X_{23} + X_{24} + X_{234}) / 4$$

4. Cálculo de la media de los modelos que cumplan: $X_1 = 0 \mid X_2 = 0$.

$$E_4 = (X + X_3 + X_4 + X_{34}) / 4$$

5. Cálculo de la varianza parcial de ambos valores obtenidos.

$$PV_{12} = ((E_1 - \bar{x})^2 + (E_2 - \bar{x})^2 + (E_3 - \bar{x})^2 + (E_4 - \bar{x})^2) / 4$$

donde \bar{x} representa la media global para todos los modelos.

6. Resta de las varianzas de los modelos de orden anterior (que compartan factor) a la varianza parcial obtenida para este modelo.

$$V_{12} = PV_{12} - V_1 - V_2$$

7. División de la varianza del modelo X_{12} entre la varianza total.

$$S_{12} = V_{12} / V(Y)$$

donde $V(Y)$ representa la varianza global para todos los modelos.

El resultado obtenido (S_{12}) se correspondería con el **Efecto principal** o **Índice de varianza de segundo orden** del modelo X_{12} , en este caso, de la combinación de los factores Aleatoriedad (v) y Accesibilidad (A).

```
## Segundo orden ####
v.xx <- function(x1, x2){
  m.xx <- c()
  m.xx <- append(m.xx, mean(df[df[x1] == 1 & df[x2] == 1,][[5]])) #1
  m.xx <- append(m.xx, mean(df[df[x1] == 1 & df[x2] == 0,][[5]])) #2
  m.xx <- append(m.xx, mean(df[df[x1] == 0 & df[x2] == 1,][[5]])) #3
  m.xx <- append(m.xx, mean(df[df[x1] == 0 & df[x2] == 0,][[5]])) #4
  var.xx <- new.var(m.xx) #5
  return(var.xx)
}

pv12 <- v.xx('X1', 'X2'); v12 <- (pv12 - v1 - v2) #6
pv13 <- v.xx('X1', 'X3'); v13 <- (pv13 - v1 - v3) #6
pv14 <- v.xx('X1', 'X4'); v14 <- (pv14 - v1 - v4) #6
pv23 <- v.xx('X2', 'X3'); v23 <- (pv23 - v2 - v3) #6
pv24 <- v.xx('X2', 'X4'); v24 <- (pv24 - v2 - v4) #6
pv34 <- v.xx('X3', 'X4'); v34 <- (pv34 - v3 - v4) #6

df[4,6] <- v12 / v.y #7
df[6,6] <- v13 / v.y #7
df[10,6] <- v14 / v.y #7
df[7,6] <- v23 / v.y #7
df[11,6] <- v24 / v.y #7
df[13,6] <- v34 / v.y #7
```

En cuanto a los **Índices de varianza de tercer orden**, el cálculo es muy similar a los anteriores, teniendo en cuenta todas las combinaciones posibles (presencia / ausencia) de los tres factores implicados. Los pasos a seguir para del factor X_{123} son:

1. Cálculo de la media de los modelos que cumplan: $X_1 = 1 \mid X_2 = 1 \mid X_3 = 1$.

$$E_1 = (X_{123} + X_{1234}) / 2$$

2. Cálculo de la media de los modelos que cumplan: $X_1 = 1 \mid X_2 = 1 \mid X_3 = 0$.

$$E_2 = (X_{12} + X_{124}) / 2$$

3. Cálculo de la media de los modelos que cumplan: $X_1 = 1 \mid X_2 = 0 \mid X_3 = 1$.

$$E_3 = (X_{13} + X_{134}) / 2$$

4. Cálculo de la media de los modelos que cumplan: $X_1 = 0 \mid X_2 = 1 \mid X_3 = 1$.

$$E_4 = (X_{23} + X_{234}) / 2$$

5. Cálculo de la media de los modelos que cumplan: $X_1 = 1 \mid X_2 = 0 \mid X_3 = 0$.

$$E_5 = (X_1 + X_{14}) / 2$$

6. Cálculo de la media de los modelos que cumplan: $X_1 = 0 \mid X_2 = 1 \mid X_3 = 0$.

$$E_6 = (X_2 + X_{24}) / 2$$

7. Cálculo de la media de los modelos que cumplan: $X_1 = 0 \mid X_2 = 0 \mid X_3 = 1$.

$$E_7 = (X_3 + X_{34}) / 2$$

8. Cálculo de la media de los modelos que cumplan: $X_1 = 0 \mid X_2 = 0 \mid X_3 = 0$.

$$E_8 = (X + X_4) / 2$$

9. Cálculo de la varianza parcial de todos los valores obtenidos.

$$PV_{123} = ((E_1 - \bar{x})^2 + (E_2 - \bar{x})^2 + (E_3 - \bar{x})^2 + (E_4 - \bar{x})^2 + (E_5 - \bar{x})^2 + (E_6 - \bar{x})^2 + (E_7 - \bar{x})^2 + (E_8 - \bar{x})^2) / 8$$

donde \bar{x} representa la media global para todos los modelos.

10. Resta de las varianzas de los modelos de orden anterior (que compartan factor) a la varianza parcial obtenida para este modelo.

$$V_{123} = PV_{123} - V_{12} - V_{13} - V_{23} - V_1 - V_2 - V_3$$

11. División de la varianza del modelo X_{123} entre la varianza total.

$$S_{123} = V_{123} / V(Y)$$

donde $V(Y)$ representa la varianza global para todos los modelos.

El resultado obtenido (S_{123}) se correspondería con el **Efecto principal** o **Índice de varianza de tercer orden** del modelo X_{123} , en este caso, de la combinación de los factores Aleatoriedad (v), Accesibilidad (A) y Aptitud (S).

```
## Tercer orden ####
v.xxx <- function(x1, x2, x3){
  m.xxx <- c()
  m.xxx <- append(m.xxx, mean(df[df[x1] == 1 & df[x2] == 1 & df[x3] == 1,][[5]])) #1
  m.xxx <- append(m.xxx, mean(df[df[x1] == 1 & df[x2] == 1 & df[x3] == 0,][[5]])) #2
  m.xxx <- append(m.xxx, mean(df[df[x1] == 1 & df[x2] == 0 & df[x3] == 1,][[5]])) #3
  m.xxx <- append(m.xxx, mean(df[df[x1] == 0 & df[x2] == 1 & df[x3] == 1,][[5]])) #4
  m.xxx <- append(m.xxx, mean(df[df[x1] == 1 & df[x2] == 0 & df[x3] == 0,][[5]])) #5
  m.xxx <- append(m.xxx, mean(df[df[x1] == 0 & df[x2] == 1 & df[x3] == 0,][[5]])) #6
  m.xxx <- append(m.xxx, mean(df[df[x1] == 0 & df[x2] == 0 & df[x3] == 1,][[5]])) #7
  m.xxx <- append(m.xxx, mean(df[df[x1] == 0 & df[x2] == 0 & df[x3] == 0,][[5]])) #8
  var.xxx <- new.var(m.xxx) #9
  return(var.xxx)
}

pv123 <- v.xxx('X1', 'X2', 'X3'); v123 <- (pv123 - v12 - v13 - v23 - v1 - v2 - v3) #10
pv124 <- v.xxx('X1', 'X2', 'X4'); v124 <- (pv124 - v12 - v14 - v24 - v1 - v2 - v4) #10
pv134 <- v.xxx('X1', 'X3', 'X4'); v134 <- (pv134 - v13 - v14 - v34 - v1 - v3 - v4) #10
```

```
pv234 <- v.xxx('X2', 'X3', 'X4'); v234 <- (pv234 - v23 - v24 - v34 - v2 - v3 - v4) #10

df[8,6] <- v123 / v.y #11
df[12,6] <- v124 / v.y #11
df[14,6] <- v134 / v.y #11
df[15,6] <- v234 / v.y #11
```

En cuanto a los **Índices de varianza de cuarto orden**, el cálculo es mas sencillo, ya que al involucrar el modelo con todos los factores (4), la varianza parcial es igual a la varianza total, por consiguiente, solo es necesario restar las varianzas parciales de los demás modelos. Los pasos a seguir para el modelo X_{1234} son:

1. Cálculo de la varianza parcial que, en este caso, es la varianza total.

$$PV_{1234} = V(Y)$$

donde $V(Y)$ representa la varianza global para todos los modelos.

2. Resta de la varianzas de los modelos de orden anterior que compartan factor a la varianza obtenida para este modelo, en este caso, todos.

$$V_{1234} = PV_{1234} - V_{123} - V_{124} - V_{134} - V_{234} - V_{12} - V_{13} - V_{14} - V_{23} - V_{24} - V_{34} - V_1 - V_2 - V_3 - V_4$$

3. División del valor anterior obtenido entre la varianza total.

$$S_{1234} = V_{1234} / V(Y)$$

El resultado obtenido (S_{1234}) se correspondería con el **Efecto principal** o **Índice de varianza de cuarto orden** del modelo X_{1234} , en este caso, de la combinación de todos los factores: Aleatoriedad (v), Accesibilidad (A), Aptitud (S) y Vecindad (N).

```
## Cuarto orden ####
pv1234 <- v.y; #1

v1234 <- (pv1234 -
  v123 - v124 - v134 - v234 - #tercer orden #2
  v12 - v13 - v14 - v23 - v24 - v34 - #segundo orden #2
  v1 - v2 - v3 - v4) #cuarto orden #2

df[16,6] <- v1234 / v.y #3
```

Por último, solo quedaría obtener los **Efectos Totales** para cada factor, es decir, la suma de todos los efectos principales de aquellos modelos que implique dicho factor. Como ejemplo, vamos a calcular el Efecto total del factor de Aleatoriedad (S_{T1}):

$$S_{T1} = S_1 + S_{12} + S_{13} + S_{14} + S_{123} + S_{124} + S_{134} + S_{1234}$$

```
## Efectos totales ####
# almacenar efectos totales
et.1 <- sum(df[6][df['X1'] == 1,]) #Factor 1. Aleatoriedad (v)
et.2 <- sum(df[6][df['X2'] == 1,]) #Factor 2. Accesibilidad (A)
et.3 <- sum(df[6][df['X3'] == 1,]) #Factor 3. Aptitud (S)
et.4 <- sum(df[6][df['X4'] == 1,]) #Factor 4. Vecindad (N)
```


Podemos tambien realizar una comprobación para verificar que los cálculos son correctos. Para ello, vamos a sumar todos los efectos principales. La sumatoria deberá aproximarse a 1.

```
# comprobacion de la varianza
print(paste0('Variance: ', sum(df[6])))
```

```
## [1] "Variance: 1"
```

En la **tabla 2** observamos los efectos principales para los 16 modelos.

Table 2: Efectos principales de los modelos.

Precisión total	Efecto principal	Modelo
0.00	0.0000000	Modelo nulo
64.55	0.0472909	v
6.58	0.0011378	A
52.49	0.0005905	vA
82.78	0.1679408	S
78.29	0.0526473	vS
76.17	0.0001368	AS
73.76	0.0023740	vAS
95.79	0.4840873	N
94.36	0.0437072	vN
95.40	0.0012055	AS
94.88	0.0019276	AN
97.95	0.1310057	vAN
98.02	0.0644728	vSN
96.08	0.0001349	ASN
100.00	0.0013406	vASN

En la **tabla 3** observamos los efectos principales de los cuatro factores individualmente, los efectos totales y la diferencia de ambos para los 16 modelos. La diferencia $S_{Ti} - S_i$ es una medida del grado de interacción de un factor con cualquier otro factor de entrada. En la práctica, consideramos que esta diferencia es significativa si es superior a 0.2 puntos.

Table 3: Efectos totales de los modelos.

Factores	Efectos individuales	Efectos totales	Diferencia
Aleatoriedad (v)	0.0472909	0.2143511	0.1670601
Accesibilidad (A)	0.0011378	0.0088478	0.0077100
Aptitud (S)	0.1679408	0.4200530	0.2521122
Vecindad (N)	0.4840873	0.7278817	0.2437944

4. Referencias

Campolongo, F., Saltelli, A., & Tarantola, S. (2000). Sensitivity Anaysis as an Ingredient of Modeling. *Statistical Science*, 15(4), 377–395. <https://doi.org/10.1214/ss/1009213004>

Crosetto, M., & Tarantola, S. (2001). Uncertainty and sensitivity analysis: tools for GIS-based model implementation. *International Journal of Geographical Information Science*, 15(5), 415–437. <https://doi.org/10.1080/13658810110053125>

- Gómez-Delgado, M., & Tarantola, S. (2006). GLOBAL sensitivity analysis, GIS and multi-criteria evaluation for a sustainable planning of a hazardous waste disposal site in Spain. *International Journal of Geographical Information Science*, 20(4), 449–466. <https://doi.org/10.1080/13658810600607709>
- Lilburne, L., & Tarantola, S. (2009). Sensitivity analysis of spatial models. *International Journal of Geographical Information Science*, 23(2), 151–168. <https://doi.org/10.1080/13658810802094995>
- Saltelli, A., Annoni, P., Azzini, I., Campolongo, F., Ratto, M., & Tarantola, S. (2010). Variance based sensitivity analysis of model output. Design and estimator for the total sensitivity index. *Computer Physics Communications*, 181(2), 259–270. <https://doi.org/10.1016/j.cpc.2009.09.018>